Лабораторная работа №1

Инференс и развёртывание языковой модели

Цель: измерить влияние длины входа, длины ответа и числа клиентов на TTFT, TPOT и пропускную способность собственного OpenAI-совместимого сервера.

1. Условия и прогноз

CPU-профиль: AMD Ryzen 7 3700X, 8 потоков, RAM 15.93 ГиБ. llama.cpp b12110, Qwen3-4B-Instruct-2507 Q4_K_M. GPU отключён. Контекст 16384: один слот в опытах 1-2, четыре в опыте 3. Полный паспорт, команды, хеши и журналы приложены.

Прогноз записан до запусков: TTFT растёт примерно линейно, на длинном входе возможен более быстрый рост; TPOT ожидается 0.10-0.25 с. При условной полосе RAM 25-40 ГБ/с чтение 2.5 ГБ весов занимает не менее 63-100 мс. Ожидалось нарушение SLO при четырёх клиентах.

SLO CPU: p90 TTFT ≤ 30 с, медиана TPOT ≤ 250 мс. Это допустимое ожидание для учебной локальной модели, но не комфортный промышленный стандарт. Goodput - число запросов, выполнивших оба индивидуальных предела, за секунду.

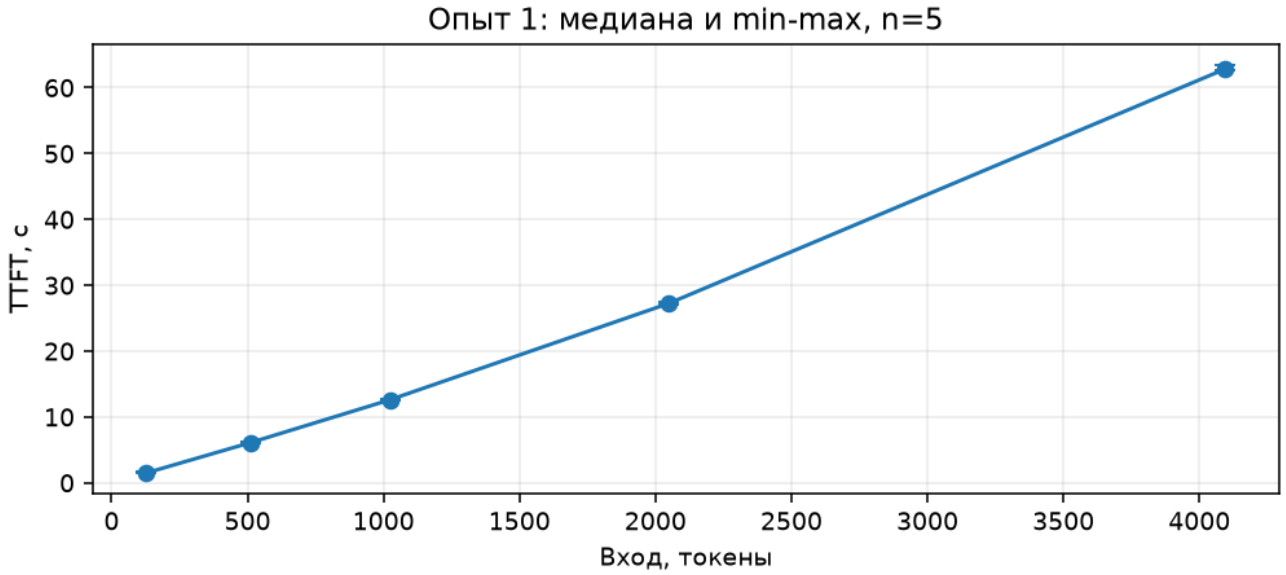
2. Память и методика

FP16: примерно 4 млрд × 2 байта = 8 ГБ весов. Файл Q4_K_M занимает 2.326 ГиБ; это размер GGUF, не полный RSS процесса. KV хранится в FP16: 2 × 36 × 8 × 128 × 2 = 147456 байт = 144 КиБ/токен. 16384 токена требуют 2304 МиБ, 8192 - 1152 МиБ. Сравнение с фактическим буфером - в паспорте и журналах.

Данные: Pride and Prejudice, Project Gutenberg №1342; исходный текст и SHA-256 сохранены. Токенизатор сервера формирует точную длину с chat template; метка запроса стоит первой. Temperature=0 и параметры sampling переданы явно, ignore_eos=true, длина проверена по usage. Прогрев каждой серии хранится отдельно. Для основных серий cache_prompt=false; дополнительный RAM-кеш отключён (--cache-ram 0).

Проверки: арифметика 400 мс / 20 мс; запросы дали ровно 64 токена; тексты при temperature=0 совпали: True. Results сохраняет t0, t1, tn, все времена фрагментов, usage, finish_reason и статус. Сводки вычислены из JSONL, артефакты загружены в MLflow.

3. Опыт 1: длина входа и TTFT



Вход	Медиана TTFT, с	Диапазон, с	Вход / TTFT, ток/с
128	1.506	1.490-1.714	85.0
512	6.114	6.067-6.190	83.7
1024	12.610	12.567-12.765	81.2
2048	27.230	27.118-27.531	75.2
4096	62.859	62.708-63.442	65.2

По пять последовательных запросов каждой длины, ответ 16 токенов. Вход/TTFT - клиентская оценка скорости prefill: она включает HTTP и первый шаг decode, поэтому не равна чистому серверному throughput prefill.

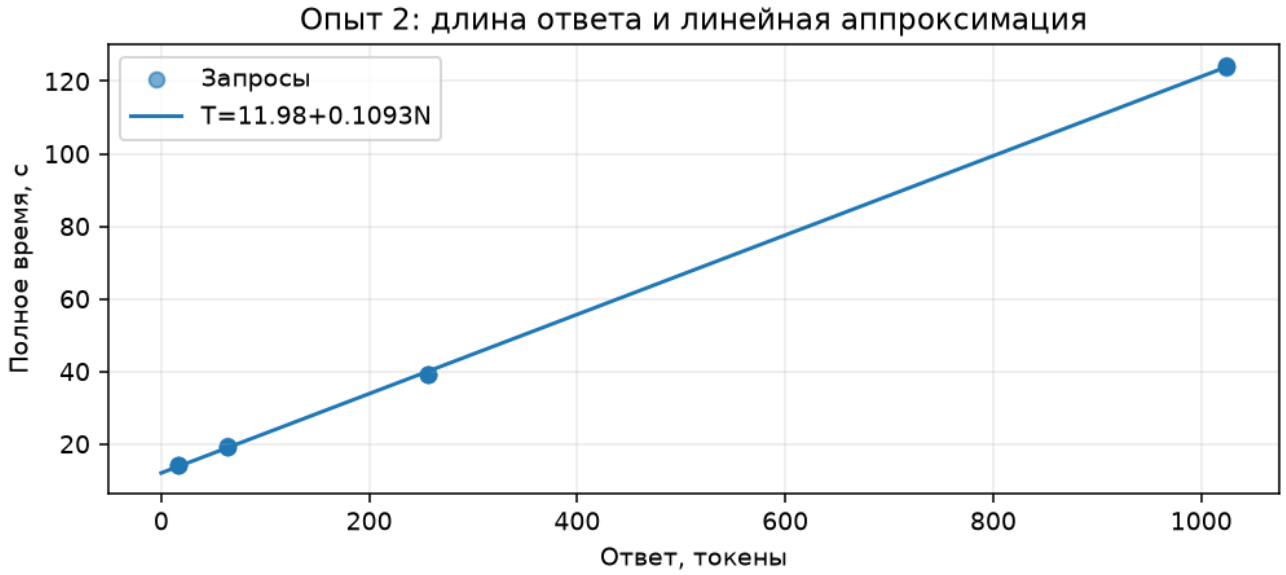
При увеличении входа с 128 до 4096 токенов (32 раза) медиана TTFT изменилась в 41.73 раза. Скорость не постоянна: она снизилась с 85.0 до 65.2 токена/с. На длинном входе возрастает стоимость внимания и обращения к KV; фиксированные накладные расходы и батчи prefill также влияют на зависимость.

Проверка кеширования префикса

Один запрос на 2048 токенов отправлен трижды с cache_prompt=true. TTFT: 27.3245, 0.1279, 0.1234 с. Отношение первого ко второму: 213.69; к третьему: 221.36. Прогрев использовал другой запрос. Повторный общий префикс позволяет повторно использовать KV и сократить обработку входа.

Для агента с 24 инструментами это экономит обработку повторяющихся описаний, если они находятся в общем префиксе. Для измерения зависимости от длины такой эффект искажает TTFT, поэтому в основной серии кеш отключён.

4. Опыт 2: длина ответа



Ответ, токены	Медиана полного времени, с	Медиана TPOT, мс
16	14.183	103.52
64	19.132	103.66
256	39.055	103.81
1024	124.135	109.02

Вход 1024 токена, по пять повторов. МНК по всем 20 запросам: T(N)=11.9762+0.109302N с; R^2=0.9999. Медиана TTFT=12.6195 с, медиана TPOT=103.80 мс.

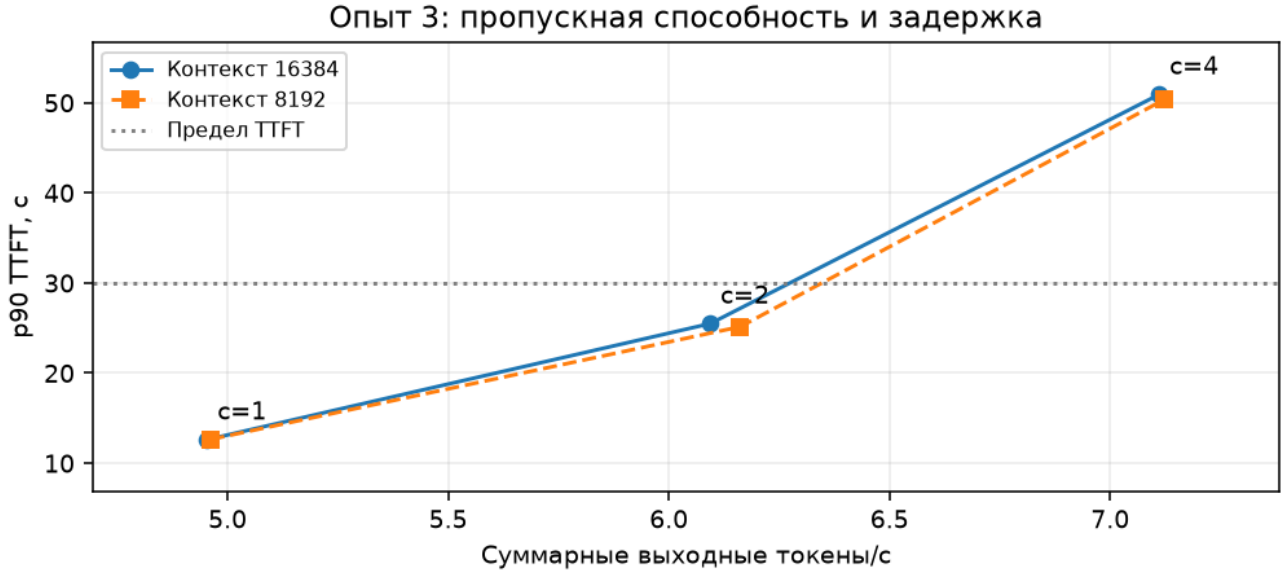
В модели T=TTFT+(N-1)·TPOT коэффициент при N близок к TPOT, а свободный член - к TTFT-TPOT. Разница с наблюдаемыми медианами возможна из-за роста KV по мере генерации и изменения производительности CPU. Линейная аппроксимация описывает тенденцию, не заменяет сырые измерения.

Граница 8/300≈0.027 с из задания относится к T4 и FP16. Здесь другой процессор, формат весов и полоса памяти. Измеренный TPOT 0.1038 с нельзя сравнивать с 27 мс как с аппаратной границей данного CPU; дополнительные расходы создают деквантование, чтение KV и вычисления.

Пример пересчёта из сырых отметок

N=64; t1-t0=12.576961 с; tn-t1=6.507346 с. TPOT=(tn-t1)/63=0.103291 с. Между 64 токенами 63 интервала. Число сетевых фрагментов вместо usage использовать нельзя.

5. Опыт 3: нагрузка и выводы



c	ток/с	запр/с	TTFT med/p90, с	TPOT, мс	goodput	SLO
1	4.95	0.039	12.57/12.61	104.0	0.039	да
2	6.09	0.048	19.15/25.49	180.8	0.048	да
4	7.11	0.056	38.22/50.93	265.4	0.000	нет

На каждом уровне 16 запросов, вход 1024, выход 128; разные фрагменты книги. Клиенты работают в замкнутом цикле: следующий запрос сразу после ответа. Throughput рассчитан по времени от первой отправки до последнего полученного ответа; подготовка запросов и прогрев исключены. Метрики сервера до/после сохранены.

Наибольшее c, выполнившее оба SLO в сетке 1,2,4: 2 (0 - ни одного). Вывод относится к проверенным уровням и этому компьютеру.

KV теоретически вмещает floor(16384/1152)=14 таких последовательностей, но сервер ограничен четырьмя слотами. Четыре запроса занимают 4608 токенов; нехватка KV не ожидается. Рост задержки нельзя автоматически считать очередью: CPU делит вычисления и память. Снимки до/после не измеряют максимум очереди внутри уровня.

Проверка уменьшенного контекста: KV 2304→1152 МиБ, лимит одного слота 4096→2048. Все входы+ответы по 1152 токенов помещаются. Максимальное прошедшее с стало 2; подробная таблица half_table.csv. Один прогон не отделяет небольшой эффект от фоновой нагрузки.

Для ЛР2-ЛР8: длинные RAG-документы и описания инструментов увеличат ожидание первого токена; общие префиксы стоит кешировать. Увеличение числа пользователей требует проверки SLO, а не только токенов/с. Контекст и slots необходимо выбирать под размер будущих запросов.

Кодогенерация: Codex помог подготовить адаптер каркаса ЛР0, генератор, анализ и отчёт. Все числа получены реальным локальным запуском. Источники: методичка ЛР1; github.com/isachvl/1Laba_is; ggml-org/llama.cpp (server README); модель bartowski/Qwen_Qwen3-4B-Instruct-2507-GGUF; gutenberg.org/ebooks/1342. Полные идентификаторы и SHA-256 - в паспорте и манифесте.